Universitätsmedizin Rostock

Genexpressionsanalyse

31460 QB1 Epidemiologie, Med. Biometrie u. Med. Informatik

Dr.rer.nat. Israel Barrantes

Institut für Biostatistik und Informatik in Medizin und Alternsforschung
Universitätsmedizin Rostock
Ernst-Heydemann-Str. 8, 18057 Rostock, Deutschland

israel.barrantes@uni-rostock.de

November 2026

Zentrale klinische Frage

„Was sind die molekularen Unterschiede zwischen Krebszellen und gesundem menschlichem Gewebe, und wie können wir diese Unterschiede nutzen, um neue therapeutische Ziele und deren Medikamente für die Krebsbehandlung zu identifizieren?“

Klinischer Hintergrund:

- Krebsheterogenität: Verschiedene Krebsarten haben unterschiedliche molekulare Signaturen
- Präzisionsmedizin: Behandlungen müssen auf die jeweilige Krebsart zugeschnitten sein
- Medikamentenresistenz: Krebszellen entwickeln unter Behandlung Resistenzen

Analyseziele:

- Molekulare Krebssignaturen: in Krebsgewebe konsistent veränderte Gene
- Therapeutische Schwachstellen: medikamentös ansteuerbare Signalwege
- Medikamentenumwidmung: bestehende Medikamente, die Krebs behandeln könnten
- Biomarker: Gene, die das Therapieansprechen vorhersagen könnten

Datensatz - Krebsproben vs. Kontrollproben

UHR = Krebsproben

- Gesamt-RNA aus 10 menschlichen Krebszelllinien
- Brust, Leber, Gebärmutterhals, Hoden, Gehirn, Haut + Immunzellen
- Relevanz: gemeinsame Merkmale mehrerer Krebsarten

HBR = Kontrollproben

- Gesamt-RNA aus Gehirnen von 23 gesunden Personen, meist 60-80 Jahre
- Relevanz: Baseline normaler Genexpression

Technische Spezifikationen

- 6 Proben (3 Krebs + 3 Kontrolle)
- Paired-End-RNA-Sequenzierung
- Chromosom-22-Subset (Bildungsdatensatz)
- Quelle: Griffith et al. (2015)

Qualitätskontrolle:

- ERCC-Spike-ins: 92 Kontrolltranskripte zur Validierung

Warum Genexpressionsanalyse?

Modulkontext

- Bioinformatik-Grundlagen → Angewendet in RNA-seq-Pipeline
- Biomarker-Kandidaten → Identifiziert durch differentielle Expression
- Individualisierte Medizin → Präzisionsonkologie-Anwendungen
- Genexpressionsdaten-Visualisierung

Essenziell für zukünftige Ärzte:

- Medizininformatik in der Praxis
- Evidenzbasierte Medizin
- Vorbereitung auf Präzisionsmedizin
- Karrierebereitschaft: Viele Methoden in der medizinischen Forschung und Diagnostik beinhalten Bioinformatik

Professionelle Kompetenzen:

- Kritische Bewertung genomischer Studien
- Verständnis personalisierter Medizin
- Grundlage für akademische Medizin

Hypothese und Lernziele

Biologische Hypothese

Krebszellen zeigen im Vergleich zu gesundem Gewebe systematische Veränderungen der Genexpression. Erwartet werden:

1. Onkogene (krebsfördernde Gene), die überexprimiert sind
2. Tumorsuppressoren (krebsverhindernde Gene), die stillgelegt sind
3. Stoffwechselwege, die verändert sind und das Krebswachstum unterstützen

Lernziele

1. Differentielle Expressionsanalyse durchführen, um Krebs-Biomarker zu identifizieren
2. Pathway-Anreicherungsanalyse durchführen, um die Krebsbiologie zu verstehen
3. Computergestützte Medikamentenumwidmung für die Suche nach Therapien einsetzen

Illumina-Sequenzierungs-Workflow

1. **Library-Vorbereitung:** RNA-Extraktion → cDNA-Synthese → Adapter-Ligation
2. **Cluster-Amplifikation:** Bridge-PCR erzeugt klonale Cluster auf Flow Cell
3. **Sequenzierung-durch-Synthese:** Fluoreszent markierte Nukleotide werden zyklisch hinzugefügt
4. **Base-Calling:** Kamera detektiert fluoreszierende Signale → Qualitätswerte zugewiesen

Paired-End-Sequenzierung

- Liest beide Enden von DNA-Fragmenten (R1 und R2)
- Bessere Mapping-Genauigkeit
- Verbesserte Splice-Junction-Detektion
- Erhöhte Quantifizierungsgenauigkeit

Wichtige Spezifikationen

- Read-Länge: 50-150 bp pro Read
- Tiefe: Millionen von Reads pro Probe
- Qualität: Phred-Scores (Q30 = 99,9% Genauigkeit)

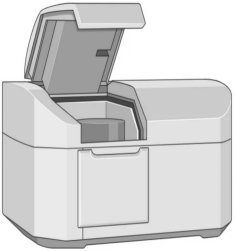
Genexpression

qPCR



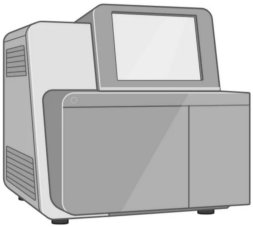
- Specific gene primers required
- Low throughput (1-100 genes)
- High precision quantification

Microarrays



- Predefined gene probes needed
- Medium throughput (~20K genes)
- Known transcripts only

RNA-seq



- **No probes required**
- **High throughput (all genes)**
- **Novel transcript discovery**

Genexpression und Quantifizierungsmethoden

Genexpressions-Grundlagen

- Zentrales Dogma: DNA → RNA → Protein
- RNA-seq misst mRNA-Abundanz
- Dynamikbereich: 0 bis >10.000 Reads

Quantifizierungs-Herausforderungen:

- Multi-Mapping-Reads
- Isoform-Komplexität
- Bias-Korrektur erforderlich

Evolution der Quantifizierungsmethoden

- **Traditionell:** Reads alignieren → pro Gen zählen
- **Neuere:** Leichtgewichtiges Mapping → probabilistische Zuordnung
- **Vorteile:** Schneller, behandelt Multi-Mapping, korrigiert Bias

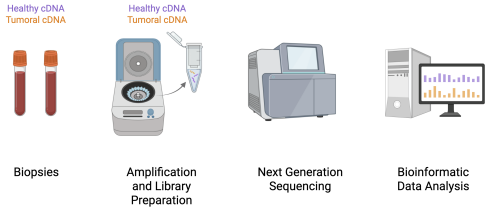
Expressionseinheiten:

- **Raw Counts:** Für statistische Analyse
- **TPM:** Transcripts Per Million (normalisiert)
- **FPKM/RPKM:** Ältere Methoden

Was ist RNA-seq?

RNA-seq-Prozess:
RNA-seq bestimmt für jedes Gen, wie viele RNA-Moleküle in einer Probe vorlagen. Dafür sind drei Schritte nötig:

1. **Reads zuordnen**: Bestimmen, von welchem Gen oder Transkript jeder Sequenzierungs-Read stammt
2. **Zählen**: Aufaddieren, wie viele Reads auf jedes Gen abgebildet werden
3. **Normalisieren**: Unterschiede in Sequenzierungstiefe und Genlänge ausgleichen



Die vollständige Analyse-Pipeline

Praktisch: Google Colab Notebook

Teil 1: Setup und Daten **(20 Min)**
Teil 2: Differentielle Expressionsanalyse mit DESeq2 **(20 Min)**
Teil 3: Pathway-Anreicherungsanalyse **(15 Min)**
Teil 4: Drug Repositioning **(15 Min)**

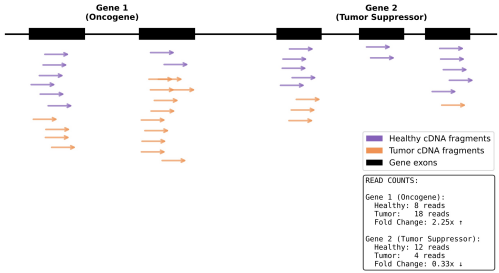
Lernansatz:

- Dauer: 90-minütiges praktisches Seminar
- Plattform: Google Colab (keine lokale Installation erforderlich)
- Daten: UHR (Krebsproben) vs. HBR (Kontrollproben), vorab mit Salmon quantifiziert
- Werkzeuge: DESeq2, g:Profiler, L1000CDS2

Warum Count-Daten verwenden?

Vorteile von Count-Daten:

- **Raw Counts**: Repräsentieren die tatsächliche Anzahl von Sequenzierungs-Reads pro Gen
- **Statistische Anforderungen**: Count-basierte statistische Modelle (wie DESeq2) benötigen ganzzahlige Counts
- **Vergleichbarkeit**: Counts können über Proben hinweg normalisiert werden für fairen Vergleich



Beispiel-Count-Tabelle

		CANCER SAMPLES			NORMAL SAMPLES		
Gene ID	**Gene Name**	**UHR_Rep1**	**UHR_Rep2**	**UHR_Rep3**	**HBR_Rep1**	**HBR_Rep2**	**HBR_Rep3**
ENSG00000070371	MAPK1	902	1148	1070	206	171	288
ENSG00000128191	DGCR2	70	152	171	814	930	687
ENSG00000100296	MIF	372	351	370	401	350	436
ENSG00000093010	COMT	1093	1185	991	287	120	260
ENSG00000070831	CDC45	107	71	138	648	658	769
ENSG00000128218	VPREB1	516	451	498	498	483	498
ENSG00000100292	HMOX1	850	1163	854	163	230	150
ENSG00000186092	BCR	184	70	122	766	873	987
ENSG00000128274	A4GALT	397	351	346	427	390	339
ENSG00000100253	APOL1	1139	891	1166	287	298	271
ENSG00000100281	HMGB1	57	84	130	649	959	987
ENSG00000128228	SDF2L1	256	304	254	304	343	313

FASTQ-Dateien (Rohdaten)

```
@SEQ_ID
GATTTGGGGTTCAAAGCAGTATCGATCAA
+
!''*((((***+))%%%++)(%%%%).1*
```

- 4 Zeilen pro Read
- Sequenz + Qualitätswerte
- Paired-End: R1 und R2 Dateien

GTF-Dateien (Annotationen)

```
chr22  ensembl_havana  gene  23179704  23318037  .  +  .
  gene_id "ENSG00000186716"; ... gene_name "BCR"; ...
```

9 Spalten, durch Tabulator getrennt; hier umbrochen

FASTA-Dateien (Referenz)

```
>chr22
NNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNNN
[...]
TAAGATGTCCTATAATTTCTGTTTGGAATATAAAATCAGCAACTAATATGTATTTTCAAA
GCATTATAAATACAGAGTGCTAAGTTACTTCACTGTGAAATGTAGTCATATAAAGAACAT
```

Verwendung: FASTA ist das Referenzgenom für die Read-Zuordnung, die GTF-Datei liefert die Genannotation

Eingabedaten - Metadaten und Genannotationen

Metadaten (samples.tsv)

- Ordnet jede Probe einer Bedingung zu: `cancer` oder `normal`
- Nennt Gewebetyp und klinischen Kontext
- 6 Zeilen: UHR_rep1-3 und HBR_rep1-3

GTF-Spalten

- Spalte 1: Chromosom (22)
- Spalte 2: Annotationsquelle (z.B. Ensembl, HAVANA)
- Spalte 3: Feature-Typ (Gen, Transkript, Exon)
- Spalten 4-5: Start- und Endposition
- Spalte 7: Strang (+ oder -)
- Spalte 9: Attribute (gene_id, gene_name usw.)

Aufbau der Count-Matrix

Zentrale Datenstruktur (counts.tsv)

- Zeilen: Transkripte (Ensembl-IDs, z.B. ENST00000...)
- Spalten: UHR_rep1-3 (Krebs) und HBR_rep1-3 (Kontrolle)
- Werte: Anzahl der Reads, die dem Transkript in der Probe zugeordnet sind

Entstehung:

1. Salmon quantifiziert die Reads pro Transkript
2. Alle Proben stehen in einer gemeinsamen Matrix

Interpretation

- Höhere Counts bedeuten höhere Expression
- Null: nicht exprimiert oder nicht nachweisbar
- Ähnliche Counts über Replikate: zuverlässige Messung
- Hohe UHR-Counts: potenzielle Onkogene
- Hohe HBR-Counts: potenzielle, in Krebs stillgelegte Tumorsuppressoren
- Ähnliche Counts in beiden Gruppen: Haushaltsgene, nicht differenziell exprimiert

Quiz: RNA-seq-Grundlagen

Aussage	**R**	**F**
RNA-seq misst direkt die Protein-Abundanz in Zellen	R	F
Paired-End-Sequenzierung liest beide Enden von DNA-Fragmenten für verbesserte Genauigkeit	R	F
Höhere Phred-Qualitätswerte (z.B. Q30) zeigen niedrigere Sequenzierungsgenauigkeit an	R	F
FASTQ-Dateien enthalten sowohl die Nukleotidsequenz als auch Qualitätswerte für jeden Read	R	F
RNA-seq kann alternatives Spleißen und Gen-Isoformen detektieren	R	F

Warum R, Python und die Kommandozeile?

R und Python

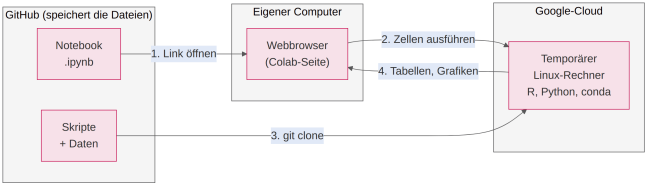
- Kostenlos (Open Source) und weltweit in der Forschung verbreitet
- R: Statistik und Grafiken; Bioconductor-Pakete für die Bioinformatik, z.B. DESeq2
- Python: allgemeine Programmiersprache, gut für Daten und Web-Dienste (unser Drug-Repositioning-Skript)
- KI-Assistenten (LLMs) erklären Code

Kommandozeile

- Befehle werden getippt statt geklickt
- Viele Programme nur dort, z.B. Salmon
- Große Sequenzdateien prüfen `head`, `wc` und `grep` in Sekunden
- Befehle in Skripten sind wiederholbar; in Colab startet `!` einen Befehl

Referenz: Buffalo, V. (2015) Bioinformatics Data Skills. O'Reilly Media

Arbeitsumgebung: Notebooks, Colab und Installation



Notebooks

- Jupyter-Notebook: Text, Code und Ergebnisse in einem Dokument (jupyter.org)
- Google Colab: kostenloser Notebook-Dienst im Browser (colab.research.google.com)
- Der Google-Rechner ist temporär; Setup-Zellen laufen in jeder Sitzung neu

Weg	Idee	Nachteil
Direkt	Programme einzeln auf dem eigenen System	Versionskonflikte
conda	getrennte „Kisten“ mit festen Versionen	etwas Einrichtung
Container (Docker)	ganzes System verpackt	groß, aufwendig

Im Seminar: conda, installiert innerhalb von Colab

Hands-on: Setup in Google Colab

Conda installieren

```
! pip install -q condacolab
import condacolab
condacolab.install()
```

Repository klonen, Daten laden

```
! git clone https://github.com/
  barrantesisrael/QB1seminar2026.git
import os
os.chdir('QB1seminar2026')
! bash getdata.sh
```

- Die Laufzeit startet nach der Conda-Installation automatisch neu; Neustart abwarten, Warnungen ignorieren
- R-Pakete über bioconda und conda-forge: DESeq2, ggplot2, gprofiler2, dplyr, tidyr, optparse
- Repository: Expressionsdaten, Count-Matrix, Analyseskripte, Referenzgenom und Annotationen

DESeq2-Verfahren

1. Normalisierung: Bibliotheksgrößen angleichen
2. Dispersionsschätzung: Variabilität zwischen Replikaten (negative Binomialverteilung)
3. Statistisches Testen: signifikant veränderte Gene
4. Multiple-Test-Korrektur: P-Werte für Tausende Tests anpassen

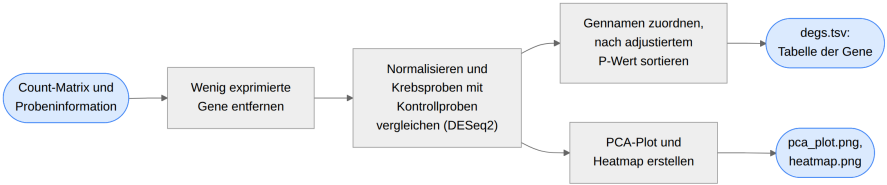
Ausgabemetriken:

- baseMean: mittlere normalisierte Counts
- log2FoldChange: Änderungsstärke (positiv = höher im Krebs)
- pvalue: statistische Signifikanz
- padj: adjustierter P-Wert

Signifikanzschwellen:

- padj $< 0{,}05$ (FDR-korrigiert)
- $|\log2FC| > 1$ (2-fache Änderung)
- Beides: starke Kandidatengene

Hands-on: DESeq2 mit run_deseq2.R



Ausführen

```
! Rscript run_deseq2.R \
    --metadata samples.tsv \
    --expression counts.tsv \
    --gtf chr22_with_ERCC92.gtf \
    --output-degs degs.tsv \
    --output-plots pca_plot.png,heatmap.png
```

Visualisierung molekularer Signaturen

PCA-Plot

- Beziehungen zwischen Proben
- Qualitätskontrolle: Replikate clustern zusammen
- PC1 & PC2 erklären Varianz
- Klare Trennung = starkes Signal

Heatmap

- 20 Gene mit dem kleinsten adjustierten P-Wert
- z-Scores der VST-Counts
- Konsistente Muster über Replikate
- Potenzielle Biomarker

Klinische Interpretation:

- PCA: Klare Trennung zeigt robuste molekulare Unterschiede
- Heatmap: Konsistente Muster über Replikate hinweg deuten auf zuverlässige Krebs-Biomarker hin

Ergebnisse - Identifizierte Krebs-Gensignaturen

Onkogene (Überexprimiert bei Krebs)

Eigenschaften:

- Positiver Log2 Fold Change (> 1)
- Statistisch signifikant (adj. $p < 0{,}05$)
- Fördern Zellproliferation
- Potenzielle Wirkstoffziele zur Hemmung

Erwartete Funktionen, z.B.:

- Zellzyklus-Progression
- Resistenz gegen Apoptose

Tumorsuppressoren (Unterexprimiert)

Eigenschaften:

- Negativer Log2 Fold Change (< -1)
- Statistisch signifikant (adj. $p < 0{,}05$)
- Hemmen Krebsprogression
- Ziele für Wiederherstellungstherapie

Erwartete Funktionen, z.B.:

- Zellzyklus-Checkpoints
- Apoptose-Induktion

Klinische Bedeutung: Diese Gensignaturen können als diagnostische Biomarker, prognostische Indikatoren und therapeutische Ziele dienen

Quiz: Grundlagen differentieller Expression

Aussage	**R**	**F**
DESeq2 verwendet eine negative Binomialverteilung zur Modellierung von RNA-seq-Count-Daten	R	F
Log2 Fold Change von +2 bedeutet, dass das Gen 4-mal stärker bei Krebs vs. normal exprimiert ist	R	F
Adjustierte p-Werte (padj) korrigieren für multiples Hypothesentesten	R	F
Gene mit padj $< 0{,}05$ und $\lvert \log2FC \rvert > 1$ gelten als signifikant differentiell exprimiert	R	F
Der Base-Mean-Expressionswert repräsentiert den durchschnittlichen normalisierten Count über alle Proben	R	F

Pathway-Anreicherungsanalyse

Idee

Die Analyse gruppiert Gene nach ihrer biologischen Funktion und prüft, ob krebsassoziierte Gene in bestimmten Prozessen überrepräsentiert sind. Beeinträchtigte Signalwege sind Ansatzpunkte für die Therapie, auch für Kombinationstherapien.

Verwendete Datenbanken:

- Gene Ontology (GO), nur biologische Prozesse (BP): zelluläre Funktionen, z.B. Zellzyklus, Apoptose
- KEGG: gut dokumentierte Signal- und Krankheitswege
- Reactome: kuratierte biologische Wege und Reaktionen

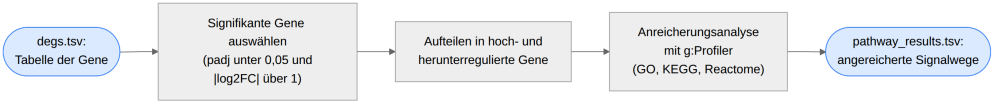
Erwartete Krebswege:

- Hochreguliert: Zellzyklusfortschritt, DNA-Replikation, Metabolismus
- Herunterreguliert: Apoptose, DNA-Reparatur, Immunantwort

Klinische Bedeutung:

- Therapeutische Vulnerabilitäten identifizieren
- Krebsbiologie verstehen
- Kombinationstherapien leiten

Hands-on: Pathway-Analyse mit pathway_analysis.R



Ausführen

```
! Rscript pathway_analysis.R \
    --input degs.tsv \
    --output pathway_results.tsv
```

- Signifikante Gene: padj $< 0{,}05$ und $|\log2FC| > 1$
- Anreicherung getrennt für hoch- und herunterregulierte Gene (g:Profiler: GO, KEGG, Reactome)

Was ist Drug Repositioning?

Neue therapeutische Anwendungen für bestehende Medikamente. Beispiel Metformin: Diabetes-Medikament, in über 200 klinischen Studien zur Krebsprävention untersucht.

Vorteile:

- Schneller: 5-10 statt 15-20 Jahre
- Bekannte Sicherheitsprofile
- Geringere Kosten und Risiken
- Teils Off-Label-Verschreibung möglich

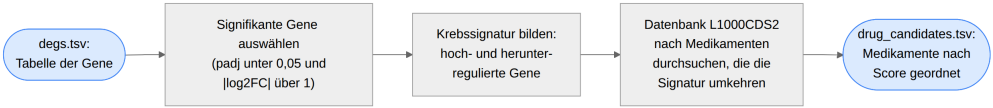
L1000CDS2-Datenbank:

- Signaturen für >20.000 Medikamente an menschlichen Zelllinien (NIH-Programm LINCS)

Medikamente, die die Krebssignatur umkehren, in vier Schritten:

1. Eingangssignatur: padj $< 0{,}05$, $|\log2FC| > 1$, max. 150 Gene je Richtung
2. Datenbanksuche
3. Bewertung
4. Rangfolge

Hands-on: Drug Repositioning mit drug_repositioning.py



Ausführen

```
! python drug_repositioning.py \
    --input degs.tsv \
    --output drug_candidates.tsv
```

- Das Skript konvertiert die DESeq2-Ergebnisse in ein L1000CDS2-kompatibles Format
- Ausgabe: drug_candidates.tsv, Medikamente nach Score geordnet

Drug Repositioning - Interpretation der Ergebnisse

L1000CDS2-Score

Überlappung zwischen Eingabe- und Medikamentensignatur (Anteil der Eingabegene). Höher = bessere Umkehr der Krebssignatur.

Positive Kontrollen

- Doxorubicin
- Paclitaxel
- Cisplatin
- Tamoxifen
- Imatinib

Ihr Auftreten stützt den Ansatz: Die Krebssignatur ist biologisch relevant

Umwidmungskandidaten

- Statine (Cholesterinsenker): Anti-Krebs-Wirkung
- Rapamycin (Immunsuppressivum): Krebsforschung
- Chloroquin (Antimalariamittel): für Krebs untersucht

Alle drei: Validierung nötig

Biologische Begründung

- Pathway-Targeting: geteilte Signalwege
- Polypharmakologie: mehrere Ziele je Medikament
- Netzwerkeffekte: verbundene Systeme
- Zufallsfunde: unerwartete Effekte

Quiz: Grundlagen des Drug Repositioning

Aussage	**R**	**F**
Drug Repositioning beinhaltet das Finden neuer therapeutischer Anwendungen für bestehende Medikamente	R	F
Computergestütztes Drug Repositioning ist schneller und weniger teuer als die Entwicklung völlig neuer Medikamente	R	F
Drug Repositioning erfordert das Starten klinischer Studien ab Phase-I-Sicherheitsstudien	R	F
Die L1000CDS2-Datenbank enthält Genexpressionssignaturen für mehr als 20.000 Medikamente	R	F
Signatur-Matching beim Drug Repositioning zielt darauf ab, Medikamente zu finden, die Krankheits-Genmuster umkehren	R	F

Klinische Translation - Präzisionsmedizin-Anwendungen

Biomarker-Anwendungen

Diagnostische Marker:

- Früherkennung von Krebs
- Molekulare Klassifizierung
- Krebs vs. benigne Unterscheidung

Prognostische Marker:

- Patientenergebnisse vorhersagen
- Risikostratifizierung
- Langzeitüberwachung

Prädiktive Marker:

- Responsive Patienten auswählen
- Ineffektive Therapien vermeiden
- Kombinationsstrategien leiten

Klinisches Entscheidungsframework

1. Tumor-RNA-seq-Profiling
2. Vergleich mit normaler Gewebe-Baseline
3. Dominante Krebs-Pathways identifizieren
4. Abgleich mit zielgerichteten Therapien
5. Behandlungsantwort überwachen

Behandlungsauswahl:

- Hohe Onkogen-Expression $\rightarrow$ Zielgerichtete Inhibitoren
- Niedriger Tumorsuppressor $\rightarrow$ Wiederherstellungstherapie
- Pathway-Aktivierung $\rightarrow$ Pathway-Wirkstoffe

Limitierungen und zukünftige Richtungen

Aktuelle Limitierungen

Technisch:

- Chr22-Teilmenge vs. vollständiges Transkriptom
- Tumor-Heterogenitäts-Herausforderungen
- Validierungslücke: Berechnung zu Klinik
- Kostenbarrieren für Routinenutzung

Klinisch:

- Zeitliche Evolution während der Behandlung
- Gewebespezifitäts-Anforderungen
- Bevölkerungsvielfalt-Überlegungen
- Workflow-Integrations-Herausforderungen

Zukünftige Richtungen

Technologisch, **z.B.**:

- Multi-Omics-Integration
- Einzelzell-RNA-seq-Analyse

Computergestützt, **z.B.**:

- Machine-Learning/KI-Ansätze
- Genregulatorische Netzwerkanalyse

Klinisch:

- Integration in Behandlungsleitlinien
- Ärzteausbildungsprogramme
- Kosten-Wirksamkeits-Studien

Schlussfolgerungen und klinische Auswirkungen

Technische Ergebnisse

- ✓ Differentielle Expressionsanalyse mit DESeq2: Count-Matrix → Kandidatengene
- ✓ Pathway-Anreicherung (GO, KEGG, Reactome) zum Verständnis der Krebsbiologie
- ✓ Medikamentenkandidaten mit L1000CDS2 berechnet
- ✓ Kandidaten kritisch bewertet: Validierung erforderlich

Wichtige Lernergebnisse

Für zukünftige Ärzte:

- Transkriptom-Kompetenz
- Dateninterpretation
- Klinische Integration
- Forschungskompetenz

Professionelle Fähigkeiten:

- Bioinformatik-Workflow-Management
- Statistische Analyse-Interpretation
- Wissenschaftliche Kommunikation
- Computergestützte Problemlösung